

Lab03_Barbosa

Danilo Dias Correia Barbosa

Laboratório 3: Dados relacionais e operações do tipo join

Considere novamente o problema de atrasos de vôos, disponível em <https://www.kaggle.com/usdot/flight-delays>. Nesta atividade, além dos dados de `flights.csv`, nós iremos utilizar informações disponíveis nos arquivos `airlines.csv` e `airports.csv`.

1. Importe, utilizando o pacote `readr`, cada um dos três arquivos disponíveis. Os objetos resultantes devem ser chamados `flights`, `airlines` e `airports`.
 - Para o arquivo de aeroportos, importe apenas as colunas `IATA_CODE`, `CITY`, `STATE`, `LATITUDE`, `LONGITUDE`;
 - Para o arquivo de vôos:
 - a. Importe apenas as colunas `DESTINATION_AIRPORT` e `ARRIVAL_DELAY`;
 - b. Leia apenas 1 milhão de linhas por vez;
 - c. Remova vôos em que o aeroporto de destino comece com a letra 1;
 - d. Remova registros em que existam pelo menos uma coluna faltante;
 - e. Determine, para cada parte do arquivo, as estatísticas suficientes para a determinação do atraso médio por aeroporto de destino;
 - f. Ao finalizar a leitura do arquivo, combine as estatísticas suficientes de modo a produzir a média de atraso por aeroporto.

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
```

```
x dplyr::lag()      masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
process_chunk <- function(input, pos) {
  input %>%
    filter(!str_starts(DESTINATION_AIRPORT, "1")) %>%
    drop_na() %>%
    filter(ARRIVAL_DELAY > 0) %>%
    group_by(DESTINATION_AIRPORT) %>%
    summarise(
      soma_tempo_atraso = sum(ARRIVAL_DELAY),
      n_atrasos = n(),
      .groups = "drop"
    )
}

flights_chunked <- read_csv_chunked(
  file = "flights.csv",
  callback = DataFrameCallback$new(process_chunk),
  chunk_size = 1000000,
  col_types = cols_only(
    DESTINATION_AIRPORT = col_character(),
    ARRIVAL_DELAY = col_double()
  )
)

airlines <- read_csv("airlines.csv")
```

```
Rows: 14 Columns: 2
```

```
-- Column specification -----
Delimiter: ","
chr (2): IATA_CODE, AIRLINE
```

```
i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
airports <- read_csv("airports.csv", col_select = c(IATA_CODE, CITY, STATE, LATITUDE, LONGITUDE))
```

```
Rows: 322 Columns: 5
```

```
-- Column specification -----
Delimiter: ","
```

```
chr (3): IATA_CODE, CITY, STATE
dbl (2): LATITUDE, LONGITUDE
```

- i Use ``spec()`` to retrieve the full column specification for this data.
- i Specify the column types or set ``show_col_types = FALSE`` to quiet this message.

Para determinar o atraso médio de vôos por aeroporto de destino, precisamos reunir para cada aeroporto:

- i. **n_atrasos_x**: Contagem de todos os vôos com atraso (`ARRIVAL_DELAY > 0`) no aeroporto de destino x.
- ii. **tempo_atraso_x**: Tempo de atraso individual de um vôo no aeroporto de destino x.

Assim, o atraso médio de vôos do aeroporto de destino x AM_x será dado pela relação:

$$AM_x = \frac{\sum tempo_atraso_x}{n_atrasos_x}$$

```
flights <- flights_chunked %>%
  group_by(DESTINATION_AIRPORT) %>%
  summarise(
    soma_total_atraso = sum(soma_tempo_atraso),
    n_total_atrasos = sum(n_atrasos),
    atraso_medio = soma_total_atraso / n_total_atrasos,
    .groups = "drop"
  )
```

- 2. Selecione a operação apropriada join para incluir, na tabela `flights`, as colunas `CITY` e `STATE` do objeto `airports`. Para executar esta tarefa:

- a. Identifique a coluna que é a chave na tabela `flights`;

R: Chave na tabela `flights`: `DESTINATION_AIRPORT`

- b. Identifique a coluna que é a chave na tabela `airports`;

R: b. Chave na tabela `airports`: `IATA_CODE`

- c. Quais são os aeroportos que estão listados em `flights`, mas estão ausentes em `airports`?

```
missing_airports <- flights %>%
  anti_join(airports, by = c("DESTINATION_AIRPORT" = "IATA_CODE"))

# Vizualizando:
missing_airports %>% pull(DESTINATION_AIRPORT)
```

`character(0)`

- d. Apresente o comando que combine ambas as tabelas, indicando explicitamente as chaves;
- e. Armazene a tabela resultante no objeto `flights`.

```
flights <- flights %>%  
  left_join(airports, by = c("DESTINATION_AIRPORT" = "IATA_CODE"))
```

3. Quantos aeroportos cada estado possui? Apresente uma tabela ordenada de forma decrescente (no número de aeroportos).

```
airports_table <- airports %>%  
  group_by(STATE) %>%  
  summarise(n_aeroportos = n(), .groups = "drop") %>%  
  arrange(desc(n_aeroportos))
```

```
# Visualizar a tabela:  
print(airports_table)
```

```
# A tibble: 54 x 2  
  STATE n_aeroportos  
  <chr>      <int>  
1 TX             24  
2 CA             22  
3 AK             19  
4 FL             17  
5 MI             15  
6 NY             14  
7 CO             10  
8 MN              8  
9 MT              8  
10 NC              8  
# i 44 more rows
```

4. Apresente um mapa representando todos os atrasos observados por aeroporto.
 - a. Carregue o pacote `leaflet`;
 - b. Combine os comandos `leaflet`, `addTiles` e `addMarkers` para a criação de um mapa básico;
 - c. Armazene o grafico em b) numa variável chamada `this`;
 - d. Adicione as duas linhas abaixo após a criação da variável `this` (apenas se você estiver usando Jupyter):

```

library(leaflet)
library(chromote)

set_default_chromote_object(
  Chromote$new(
    browser = Chrome$new(args = c("--no-sandbox", "--disable-gpu", "--headless"))
  )
)

# Criação do mapa básico e armazenamento na variável 'this':
this <- leaflet(flights) %>%
  addTiles() %>%
  addMarkers(
    lng = ~LONGITUDE,
    lat = ~LATITUDE,
    popup = ~paste0("<b>Aeroporto: </b>", DESTINATION_AIRPORT,
                     "<br><b>Atraso Médio: </b>", round(atraso_medio, 2), " min")
  )

# Para exibir o mapa no RStudio ou R Markdown:
this

```



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-30 14:24:19 -03"
```